

# Eine Übersicht über Crossover-Operationen für genetische Algorithmen Seminar Organic Computing

Gerald Siegert  
Matrikelnummer: 1450117

Universität Augsburg  
Lehrstuhl für Organic Computing

**Abstract.** Crossover-Operationen (CO) sind ein wesentlicher Bestandteil von Genetischen Algorithmen (GA) und sind maßgeblich für deren Effizienz. Daher soll ein kleiner Überblick über verschiedene COs und deren Klassifizierung gegeben werden. Zunächst werden eindimensionale Repräsentationen betrachtet, welche zugleich den Fokus dieser Arbeit bilden. Dabei werden für Darstellungen als Binärwerte, Ganzzahlen bzw. entsprechende Permutationen, Fließkommazahlen und Zeichenketten aufgezeigt, bei welchen Problemen bzw. Anwendungsfällen welche Codierung geeignet ist, und einige der dafür optimierten COs aufgezeigt. Ebenfalls betrachtet werden mehrdimensionale Repräsentationen wie Arrays, Bäume und Matrizen, für die eine kurze Übersicht gegeben wird. Zudem wird in einer kurzen Übersicht darauf eingegangen, wann es geeignet ist, anwendungsspezifische Codierungen zu nutzen und anzuwenden. Zusätzlich werden einige universell nutzbare COs aufgezeigt, die nicht an eine spezielle Repräsentation der Daten gebunden sind. Auch wird kurz erläutert, warum möglichst eine Codierung verwendet werden soll, welche direkt den Suchraum ohne Konvertierungen absucht und warum nicht jede vermeintlich geeignete CO auch wirklich geeignet ist.

## 1 Einführung in genetische Algorithmen

Genetische Algorithmen (GA) sind genauso wie andere Evolutionäre Algorithmen im Allgemeinen aus der Biologie übernommen worden. Wie der Name schon aussagt, basieren sie auf dem Prinzip der Evolution, bei der basierend auf einer Ausgangspopulation möglicher Lösungen neue Kinder erzeugt werden, welche dann die Vorfahren in der Population verdrängen. Welche Vorfahren, oder gar die erzeugten Kinder, dabei konkret verdrängt werden, entscheidet sich anhand einer Fitness-Funktion, bei der die gefundenen Lösungen der Population evaluiert werden, und anschließend nur die besten in der Population verweilen dürfen.

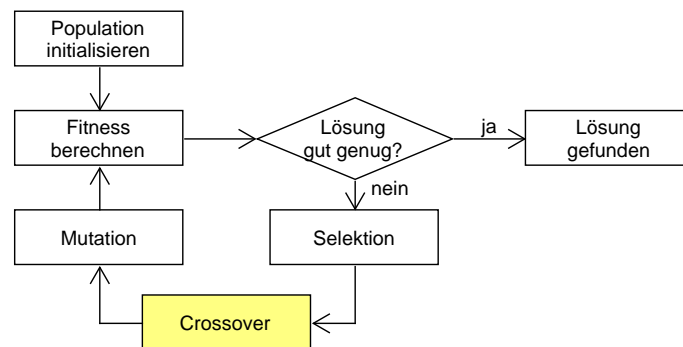


Fig. 1: Grundlegender Ablauf eines genetischen Algorithmus

Die wichtigen Parameter eines GA sind zum einen die Selektion der Eltern, die Crossover-Operation (CO) um aus den ausgewählten Eltern neue Kinder zu erzeugen, sowie anschließende Mutationen um neues Erbmateriel zu generieren und den Suchraum somit besser abzudecken. Maßgeblich für die Qualität und Effizienz eines GA ist dabei die in Fig. 1 markierte CO.

In dieser Seminararbeit soll daher nun ein kleiner Überblick gegeben werden, für welche Codierung der Daten, Probleme und Anwendungen sich welche COs eignen. Dabei wird im Abschnitt 2 zunächst eine Übersicht über die grundlegenden Klassifikationen gegeben, bevor im Abschnitt 3 eindimensionale und im Abschnitt 4 mehrdimensionale Repräsentationen behandelt werden. Abschließend werden im Abschnitt 5 anwendungsspezifische und im Abschnitt 6 universelle COs aufgezeigt, bevor in Abschnitt 7 zusammengefasst wird, worauf man bei der Auswahl der Codierung bzw. der CO achten muss.

## 2 Klassifizierungen von Crossover-Operationen

COs gibt es für viele verschiedene Arten von Anwendungen und Daten. Jedoch sind nicht alle möglichen Operationen für jede Anwendung und Daten-

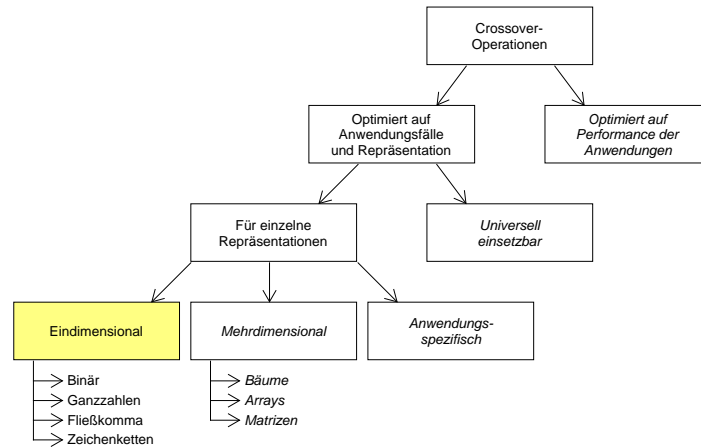


Fig. 2: Übersicht der Klassifizierung (nach [18])

art geeignet. Pavai und Geetha haben daher in [18] bereits einen sehr umfassenden Überblick über die verschiedenen Arten von COs gegeben, weshalb sich diese Seminararbeit an deren Arbeit orientiert. Die COs können dazu in die in Fig. 2 gezeigten Kategorien eingeteilt werden. Da für die Daten häufig eindimensionale Darstellungsformen genutzt werden, befasst sich diese Seminararbeit hauptsächlich mit diesen Codierungen. Für die kursiv markierten Klassifizierungen wird daher nur ein kurzer Überblick bzw. im Falle der performance-optimierten COs darauf verzichtet.

Die Basis aller verschiedenen COs bilden die elementaren Operationen, welche die Gene der beiden Eltern an einer oder mehreren Stellen teilen und daraus die neuen Kinder erzeugen. Entsprechend werden sie auch *N-Point-Crossover* bzw. im Speziellen auch *One-Point-Crossover* bzw. *Two-Point-Crossover* genannt. Darauf basierend gibt es noch weitere Basis-Operationen, wie *Segmented Crossover*, bei der die Gene in eine bestimmte Anzahl Segmente anstatt an einer bestimmten Anzahl an Stellen geteilt werden, [22] oder wie *Uniform Crossover*, bei der für jedes Gen des Kindes zufällig ausgewählt wird, von welchem Elternteil das Gen vererbt wird.

### 3 Eindimensionale Repräsentation

Unter eindimensionaler Repräsentation wird die Darstellung der Daten in den elementaren Datentypen verstanden, wodurch die Daten linear vorliegen. Dadurch ist die Handhabung mit den Daten auch entsprechend einfach und in vielen Anwendungsfällen ohne großen Aufwand durchführbar. Daher werden diese Codierungen häufig genutzt, weshalb es dafür auch eine große Anzahl an COs gibt.

Zuerst wird im Abschnitt 3.1 ein Überblick über spezielle Anwendungsfälle und mögliche COs für die Binär-Codierung gegeben. Anschließend wird in Abschnitt 3.2 auf ganzzahlige Codierung allgemein bzw. auf Permutationen im Speziellen eingegangen, in Abschnitt 3.3 folgen Fließkomma-Darstellungen sowie in 3.4 Zeichenketten.

### 3.1 Binäre Codierung

Eine Codierung als Binärwerte bedeutet, dass die vom GA bearbeiteten Daten, als eine Kette von 0 und 1 dargestellt sind. Der große Vorteil einer binären Codierung liegt vor allem darin, dass die Handhabung dieser Daten sehr einfach und platzsparend ist, weshalb diese Art der Darstellung prinzipiell von jeder Anwendung genutzt werden kann. Ebenfalls ein großer Vorteil liegt darin, dass GAs mit Binärwerten aufgrund des geringen Alphabets und der damit verbundenen schnellen Evaluation der Fitness sehr effizient sein können. [8]

Eine binäre Codierung ist u. A. vor allem für folgende Anwendungen und Problemfälle von Vorteil: [18]

**Classification Problem** Lösung soll in verschiedene Kategorien klassifiziert werden. [9]

**Multimodal Spin Lattice Problem** Suchen eines minimalen Energiezustandes für 450 Spins mit je vier Zuständen auf einem 2D-Gitter. [16]

Passende Crossover-Operationen hierfür sind:

**Self-Crossover** Tauschen von einzelnen Bits innerhalb des Chromosoms. [17]

**Supplementary Crossover** Nutzt das *Center of Gravity*-Paradigma um Kinder zu erzeugen. [3]

**Generalized crossover** Interpretiert Chromosom als Ganzzahl und dividiert diese durch eine andere, zufällig ausgewählte Ganzzahl. [7]

### 3.2 Codierung als Ganzzahlen und Permutationen

Da ganzzahlige Werte ebenfalls sehr einfach als Binärwerte dargestellt werden können, können COs für Binärwerte prinzipiell auch für ganzzahlige Werte eingesetzt werden. Natürlich gibt es auch entsprechende Anwendungsfälle und COs, die speziell für ganzzahlige Darstellungen geeignet und optimiert sind, auf die hier aber verzichtet wird und stattdessen auf Ketten von ganzzahligen Werten, also Permutationen, eingegangen wird.

Der Unterschied zwischen einfachen, ganzzahligen Darstellungen und Permutationen liegt darin, dass bei Permutationen die komplette Zahlenfolge als mehrere aneinandergereihte Zahlen betrachtet werden muss. Entsprechend können keine COs für Binärwerte und einfache, ganzzahlige Werte eingesetzt werden, sondern COs, welche die Permutationen entsprechend berücksichtigen. Dies ist u. A. bei folgenden Anwendungen und Problemen der Fall:

**Traveling Salesman Problem (TSP)** Mehrere Orte müssen mit einer möglichst kurzen Strecke miteinander verbunden werden. [1]

**Graph Coloring Problem** Knoten eines Graphen mit möglichst wenigen, verschiedenen Farben einfärben. [14]

**Quadratic Assignment Problem** Summe der Distanzen zwischen Punkten minimieren, ähnlich wie TSP, nur mit quadratischer Kostenfunktion. [13]

Passende COs für Permutationen lassen sich in verschiedene Kategorien einteilen, welche sich basierend auf dem grundlegenden Vorgehen der COs klassifizieren lassen. Im Folgenden werden nun einige positionsbasierte, kantenbasierte und folgenbasierte COs vorgestellt. Daneben gibt es aber auch noch weitere, wie z. B. teilmengenbasierte, die auf Basis von Genom-Teilmengen arbeiten, *Cut and Splice*-basierte, die einen Teil der Elterngenome tauschen, oder distanzbasierte COs, bei denen die Anzahl der unterschiedlichen Gene zwischen allen Elternteile gleich sein muss.

**Positionsbasierte COs** beeinflussen die Gene der erzeugten Kinder basierend auf den Positionen der einzelnen Gene. Dies sind u. A. folgende COs:

**Partially Mapped Crossover (PMX)** Wählt zufällig zwei Punkte aus und tauscht alle Werte dazwischen mit dem anderen Elternteil. Bei der Erweiterung Uniform PMX werden einzelne Gene anstatt eines ganzen Segments getauscht. [1] [12] [13]

**Position Based Crossover (POS)** Wählt einige zufällige Positionen im ersten Elternteil aus und verschiebt die ausgewählten Werte zu den korrespondierenden Positionen im anderen Elternteil. [12]

**Kantenbasierte COs** erzeugen basierend auf Kanten der Eltern(-knoten) neue Kinder. Darunter fallen u. A. folgende COs:

**Edge Crossover** Wählt einen Knoten mit der geringsten Kantenzahl aus und fügt ihn zum neuen Kind hinzu und löscht ihn aus den anderen Kantenlisten. [12]

**Edge Exchange Crossover (EXX)** Vererbt zunächst alle Elternkanten um einen Kreis zu bilden und entfernt dann ungültige Kanten. Falls kein Kreis gebildet werden konnte, werden alle Kanten vererbt. [26]

**Folgenbasierte COs** beeinflussen vor allem die Reihenfolge der Gene. Sie lassen sich in weitere Unterkategorien einteilen. Darunter fallen z. B. folgende COs:

**Merging Crossover (MOX)** Beide Eltern werden zuerst zufällig zusammengefügt und anschließend in die beiden Kinder geteilt. [14]

**Non-Wrapping Ordered Crossover** Erstellt Lücken und füllt diese wieder auf, ohne dabei die absolute Reihenfolge der Gene zu verlieren. [1]

Daneben gibt es auch noch weitere COs, welche sich neben den hier vorgestellten Unterkategorien für folgenbasierte COs (verschmelzende und absolute Reihenfolge) in z. B. sortierende oder angrenzende, folgenbasierte COs klassifizieren lassen.

### 3.3 Codierung als Fließkommazahl

Im Gegensatz zur Codierung als Ganzzahlen bzw. Binärwerte lassen sich als Fließkommazahl codierte Daten viel genauer darstellen, haben dadurch aber auch einen deutlich größeren Suchraum für mögliche Lösungen. Dennoch liegt gerade darin der Vorteil, da die Art der Datencodierung möglichst mit der Codierung des Suchraumes übereinstimmen sollte. Dadurch entfällt die notwendige Konvertierung der Daten, wodurch letztlich die Geschwindigkeit und damit die Effizienz des GAs deutlich erhöht wird. Ebenso ist von Vorteil, dass große Suchräume mit kontinuierlichen Daten auf einfache Art und Weise abgesucht werden können anstatt lediglich mit diskreten Daten wie bei der Binärcodierung. [8]

Entsprechend lassen sich vor allem Anwendungen bzw. Probleme, welche einen kontinuierlichen Suchraum besitzen, mit Fließkomma-Codierungen effizient ausführen. Darunter fallen z. B. folgende Anwendungen und Probleme:

**Animal Diet Formulation Problem** Erstellung eines Ernährungsplans mit möglichst vielen Nährstoffen zu minimalen Kosten. [19]

**Electromagnetic Optimization** Handhabung und Optimierung von elektromagnetischen Werten in einem kontinuierlichem Suchraum. [15]

**Revenue Management in Airlines** Zuweisen von begrenzten Ressourcen einer Airline (Flugzeuge, Personal, ...), um den Gewinn zu maximieren. [21]

Als Fließkommazahlen codierte Daten kann man auf mehrere Arten verarbeiten, mit deren Basis die COs funktionieren. Dies sind z. B. folgende Arten bzw. COs:

**Taguchi Crossover (TC)** Nutzt statistische Daten innerhalb einer Matrix um das beste Ergebnis zu finden. [5]

**Average Crossover** Modifizierter *One-Point-Crossover*, bei dem die Durchschnittswerte zwischen beiden Eltern anstatt den Elternwerten der einzelnen Gene genutzt werden. [19]

**Fuzzy Arithmetic Weighted Mean (FAWM)** Berechnet mithilfe der Fuzzy-Arithmetik die Werte der Kinder. [21]

Daneben gibt es aber auch noch einige weitere Klassifizierungen wie z. B. den gewichteten Durchschnitt oder dem *Center of Mass Crossover (CMX)*, welcher den gleichnamigen Ansatz nutzt um mithilfe des Massenzentrums der Eltern neue Kinder zu erzeugen. [27]

### 3.4 Codierung als Zeichenkette

Bei einer Codierung der Daten in einer Zeichenkette werden die Chromosomen als Buchstaben codiert. Dies eignet sich daher entsprechend vor allem für textbasierte Anwendungen. Aber auch das **DNA Sequencing Problem** lässt sich damit einfach bearbeiten. Dabei werden die einzelnen DNA-Proteine als Buchstaben bezeichnet, wodurch sich eine Zeichenkette ergibt, die mithilfe von entsprechenden COs einfach bearbeitet werden kann. [18]

Bei einer Zeichenketten-Darstellung der Daten muss man zwischen einer festen Länge der Zeichenkette und einer variablen Länge unterscheiden. Abhängig ist dies vor allem von der Länge der beiden Eltern, also ob die Zeichenketten der Eltern die gleiche oder eine unterschiedliche Länge besitzen.

**Zeichenketten mit festen Längen** gelten als einfacher zu Handhaben, da nicht entschieden werden muss, welche Gene hinzugefügt oder entfernt werden müssen. Jackson hat in seiner Masterarbeit [10] folgende beiden COs vorgestellt, welche man speziell dafür nutzen kann:

- C1 Crossover** Ermittelt Sekundärstruktur-Elemente und legt die Schnittpunkte auf unstrukturierte Regionen und trennt somit unterschiedliche Strukturtypen.
- C2 Crossover** Legt die Schnittpunkte basierend auf der Frequenz der angrenzenden Genompaare der Sekundärstruktur fest.

**Zeichenketten mit variablen Längen** werden dagegen vor allem im Bereich der biologischen Anwendungen wie die Bearbeitung von DNA- bzw. RNA-Sequenzen genutzt. Dies liegt daran, dass sich diese Art der Darstellung auch in der Natur wiederfindet, wo Chromosomen ebenfalls unterschiedliche Längen haben. Bei Zeichenketten mit variablen Längen liegt eines der Hauptprobleme in der Entscheidung, welche Gene hinzugefügt und welche Gene entfernt werden sollen, wobei die Gesamtanzahl der Gene der Kinder der Anzahl aller Elterngene entsprechen soll. Dazu gibt es z. B. folgende COs, welche hierfür genutzt werden können:

- Internal Crossover** Basiert auf der Annahme, dass Gene der kleineren Sequenz ohne Überhang mit jedem Block der längeren Sequenz angeordnet werden können. [4]
- Equal Crossover** Erzeugt Kinder, welche die gleiche Längen wie die Eltern besitzen. [24]
- Inside Crossover** Erzeugt Kinder, die länger als der kurze und kürzer als der lange Elternteil sind. [24]

## 4 Mehrdimensionale Repräsentation

Neben den verschiedenen eindimensionalen Repräsentationen der Daten gibt es natürlich auch mehrdimensionale Repräsentationsarten. Damit sind nicht lineare, sondern komplexere Datenstrukturen gemeint, die entsprechend komplizierter zu Handhaben sind. Da es aber auch Anwendungen gibt, die mehrdimensionale Daten verarbeiten, gibt es auch entsprechende COs, um solche Daten einfach verarbeiten zu können.

**Arrays** dürften wohl eine der einfachsten Arten der mehrdimensionalen Repräsentationen darstellen. Sie bilden nicht mehr als eine Verkettung von mehreren linearen Datensätzen. Diese Art der Codierung kann für verschiedene Probleme genutzt werden wie z. B. das TSP oder die Suche nach pareto-optimalen Lösungen, bei denen nicht alle Zieleigenschaften optimal sein können.

Einige für Arrays passende COs werden als *Orthogonal Array Based Crossovers* zusammengefasst, was eigentlich zwei COs sind. Die erste CO heißt *Orthogonal Crossover* und erzeugt die Kinder, indem die Elterngene basierend auf den Kombinationen eines orthogonalen Array ausgewählt werden. Die zweite CO namens *Main Effect Crossover* wählt die Kindergene im orthogonalen Array dagegen basierend auf deren Effekte aus, wodurch Kinder mit den besten Haupteffekten der Eltern generiert werden. [6]

**Weitere mehrdimensionale Repräsentationen** sind beispielsweise *Bäume* oder *Matrizen*, bei denen die Daten entsprechend strukturiert und aufgebaut sind. Beide Darstellungsarten lassen sich u. A. auch durch ähnliche COs bearbeiten, wie z. B. den *Reijmers Crossover Operator*, welcher aus den Distanzen zwischen den einzelnen Baumknoten eine Distanzen-Matrix erstellt, und diese mit einer weiteren, speziell dafür generierten Matrix addiert. [20]

## 5 Anwendungsspezifische Codierung der Daten

Natürlich muss man nicht immer eine der üblichen ein- oder mehrdimensionalen Repräsentationsformen nutzen, wenn man einen GA entwickeln möchte. Es gibt auch Anwendungsfälle wie z. B. in der Robotik, [11] bei denen es geeigneter ist, eine speziell für die Anwendung zugeschnittene und optimierte Daten-Codierung zu nutzen.

Die einfachste Variante dafür ist eine Art hybride Codierung zu nutzen, bei der zwei lineare Darstellungsformen miteinander kombiniert werden. Aguilar-Ruiz et al. haben dies in ihrer Arbeit [2] gemacht und diskrete und kontinuierliche Darstellungsformen miteinander kombiniert, unterscheiden ihre *Natural Encoding* jedoch von anderen hybriden Codierungen. Dennoch funktioniert ihr dabei entwickelter GA für klassische hybride und die *Natural Encoding*.

Daneben gibt es aber noch zahlreiche weitere Möglichkeiten, die Daten anwendungsspezifisch zu codieren. Einige davon wären z. B. *Restricted Growth Function*-basierte Techniken und COs, [25] oder die Möglichkeit, Fuzzy-Logiken zu nutzen. [23]

## 6 Universale Crossover-Operationen

Neben den in dieser Seminararbeit vorgestellten spezifischen Darstellungsformen und entsprechenden COs gibt es aber auch noch einige COs, welche nicht auf eine bestimmte Repräsentationsart beschränkt sind, sondern mehrere verschiedene auf gleiche Art und Weise bearbeiten und daraus neue Kinder erzeugen können.



Dies trifft zwar auch auf alle elementaren COs wie die *N-Point-Crossover* zu, aber auch auf zahlreiche weitere COs, wie z. B. der in [12] erwähnte *Sorted Match Crossover*. Diese CO basiert auf den Kosten bzw. Fitness der Eltern und erzeugt neue Kinder, indem ein Teil eines teuren bzw. guten Elternteils mit einem Teil eines billigen bzw. schlechten Elternteils kombiniert werden.

Ähnlich wie den *Uniform Crossover Operator* gibt es aber auch noch weitere COs, bei denen die Gene der Eltern zufallsbasiert vererbt werden. Ziemlich ähnlich funktionieren so z. B. der *Box Crossover* bzw. *Extended Box Crossover*, bei denen die Gene der Kinder zufällig aus denen der Elternteile ausgewählt werden, wobei letzterer einen größeren Suchraum nutzt. [28]

Zudem besteht auch noch die Möglichkeit, zwei vorhandene COs miteinander zu kombinieren, wobei hier eine aufeinanderfolgende oder eine voneinander unabhängige (hybride) Ausführung möglich ist. Ein Beispiel für eine CO, welcher zwei COs kombiniert wäre der *Uniform Wise Crossover (UWX)*, welcher den *Uniform Crossover* mit dem *Parameter Wise Crossover* kombiniert. [15]

Alternativ können auch heuristische COs genutzt werden. Eine davon nennt sich *Adaptive Crossover*, welche die Fitness-Werte der Elterngene bei der Erzeugung neuer Kinder berücksichtigt.

## 7 Zusammenfassung

Neben den hier vorgestellten COs gibt es für alle Darstellungsformen und deren Kategorisierungen noch zahlreiche weitere COs, von denen aufgrund der Länge dieser Seminararbeit viele nicht im Ansatz erwähnt wurden bzw. konnten. Wie Anfangs erwähnt haben Pavai und Geetha in [18] eine ausführliche Übersicht erstellt, die sich ebenfalls lohnt, wenn man auf der Suche nach einer passenden CO für seine Anwendung ist.

Natürlich ist nicht jede der vorgestellten Darstellungsformen für alle Anwendungen geeignet, so macht es z. B. wenig Sinn, eine TSP-Anwendung mithilfe von Binärcodierung oder mit einer elementaren bzw. universellen CO zu entwickeln, obwohl sich dies prinzipiell für jede Anwendung eignet. Dies liegt vor allem am Grundsatz, dass sich der Lösungsraum und der Suchraum möglichst gering unterscheiden sollten. [8] Als Konsequenz daraus sind COs, welche direkt den Lösungsraum durchsuchen, am effizientesten, da dadurch der Aufwand für die Konvertierung der Daten entfällt. Aber auch die Auswahl zwischen geeigneten COs ist eine Frage der Effizienz, da eine CO für eine konkrete Anwendung effizienter sein kann als eine andere geeignete CO.

Es spielt auch eine Rolle, ob es angebracht ist, eine anwendungsspezifische Codierung zu nutzen anstatt einer Standard-Codierung, da eine spezifische Codierung je nach Anwendung die Performance enorm steigern kann. Daher bietet sich aufgrund der einfachen Implementation zwar oftmals eine eindimensionale Codierung an, welche aber nicht immer die effizienteste sein muss. Man muss daher immer im Einzelfall abwägen, ob eine anwendungsspezifische Codierung und CO effizienter wäre als eine Standard-Codierung.

## References

1. Abdoun, O., Abouchabaka, J.: A comparative study of adaptive crossover operators for genetic algorithms to resolve the traveling salesman problem. CoRR abs/1203.3097 (2012), <http://arxiv.org/abs/1203.3097>
2. Aguilar-Ruiz, J.S., Giraldez, R., Riquelme, J.C.: Natural encoding for evolutionary supervised learning. *IEEE Transactions on Evolutionary Computation* 11(4), 466–479 (Aug 2007)
3. Angelov, P.: Supplementary crossover operator for genetic algorithms based on the center-of-gravity paradigm. *Control and Cybernetics* Vol. 30, no 2, 159–176 (2001)
4. Baake, M.: Repeat distributions from unequal crossovers. *ArXiv e-prints* (Mar 2008)
5. Chan, K.Y., Aydin, M.E., Fogarty, T.C.: A taguchi method-based crossover operator for the parametrical problems. In: *Evolutionary Computation, 2003. CEC '03. The 2003 Congress on*. vol. 2, pp. 971–977 Vol.2 (Dec 2003)
6. Chan, K., Kwong, C., Jiang, H., Aydin, M., Fogarty, T.: A new orthogonal array based crossover, with analysis of gene interactions, for evolutionary algorithms and its application to car door design. *Expert Systems with Applications* 37(5), 3853 – 3862 (2010), <http://www.sciencedirect.com/science/article/pii/S0957417409009750>
7. Coli, M., Gennuso, G., Palazzari, P.: A new crossover operator for genetic algorithms. In: *Proceedings of IEEE International Conference on Evolutionary Computation*. pp. 201–206 (May 1996)
8. Herrera, F., Lozano, M., Verdegay, J.: Tackling real-coded genetic algorithms: Operators and tools for behavioural analysis. *Artificial Intelligence Review* 12(4), 265–319 (1998), <http://dx.doi.org/10.1023/A:1006504901164>
9. Ho, S.Y., Liu, C.C., Liu, S.: Design of an optimal nearest neighbor classifier using an intelligent genetic algorithm. *Pattern Recognition Letters* 23(13), 1495 – 1503 (2002), <http://www.sciencedirect.com/science/article/pii/S0167865502001095>
10. Jackson, D.: Modified crossover operators for protein folding simulation with genetic algorithms. Master's thesis, Carleton University Ottawa (Sep 2004)
11. Koza, J.R.: *Genetic programming: on the programming of computers by means of natural selection*, vol. 1. MIT press (1992)
12. Kumar, R., Gopal, G., Kumar, R.: Novel crossover operator for genetic algorithm for permutation problems 3 (May 2013)
13. Misevičius, A., Kilda, B.: Comparison of crossover operators for the quadratic assignment problem. In: *Information technology and control*. vol. 34 (2005)
14. Mumford, C.L.: New Order-Based Crossovers for the Graph Coloring Problem, pp. 880–889. Springer Berlin Heidelberg, Berlin, Heidelberg (2006), [http://dx.doi.org/10.1007/11844297\\_89](http://dx.doi.org/10.1007/11844297_89)
15. Otevrel, V., Raida, Z.: Mean-adaptive real-coding genetic algorithm and its applications to electromagnetic optimization (part one). vol. 16, p. 19. CZECH TECHNICAL UNIVERSITY (2007)
16. Pál, K.F.: Selection schemes with spatial isolation for genetic optimization, pp. 169–179. Springer Berlin Heidelberg, Berlin, Heidelberg (1994), [http://dx.doi.org/10.1007/3-540-58484-6\\_261](http://dx.doi.org/10.1007/3-540-58484-6_261)
17. Pal, N.R., Kundu, M.K., Nandi, S.: Application of a new genetic operator in feature selection problems. In: *TENCON '98. 1998 IEEE Region 10 International Conference on Global Connectivity in Energy, Computer, Communication and Control*. vol. 1, pp. 37–40 vol.1 (1998)

18. Pavai, G., Geetha, T.V.: A survey on crossover operators. *ACM Comput. Surv.* 49(4), 72:1–72:43 (Dec 2016), <http://doi.acm.org/10.1145/3009966>
19. Rahman, R.A., Ramli, R.: Average concept of crossover operator in real coded genetic algorithm. vol. 63, pp. 73–77. IACSIT Press, Singapore (2013), <https://search.proquest.com/docview/1522282250?accountid=8429>, copyright - Copyright IACSIT Press 2013; Dokumentbestandteil - Tables; ; Equations; Zuletzt aktualisiert - 2014-05-08
20. Reijmers, T., Wehrens, R., Daeyaert, F., Lewi, P., Buydens, L.: Using genetic algorithms for the construction of phylogenetic trees: application to g-protein coupled receptor sequences. *Biosystems* 49(1), 31 – 43 (1999), <http://www.sciencedirect.com/science/article/pii/S0303264798000331>
21. Sadeghi, M., Sadeghi, R., Mousavi, S., Khanmohammadi, S.: Improved genetic algorithms by means of fuzzy crossover operators for revenue management in airlines. *World Applied Sciences Journal* 2(6), 838–846 (2013)
22. Sharapov, R.R.: Genetic Algorithms: Basic Ideas, Variants and Analysis. InTech (Jun 2007), [https://www.intechopen.com/books/vision\\_systems\\_segmentation\\_and\\_pattern\\_recognition/genetic\\_algorithms\\_\\_basic\\_ideas\\_\\_variants\\_and\\_analysis](https://www.intechopen.com/books/vision_systems_segmentation_and_pattern_recognition/genetic_algorithms__basic_ideas__variants_and_analysis)
23. Sharma, S.K., Irwin, G.W.: Fuzzy coding of genetic algorithms. *IEEE Transactions on Evolutionary Computation* 7(4), 344–355 (Aug 2003)
24. Stringer, H., Wu, A.S.: Bloat is unnatural: An analysis of changes in variable chromosome length absent selection pressure. Univ. Central Florida, Tech. Rep. CS-TR-04-01 (2004)
25. Swift, S., Tucker, A., Crampton, J., Garway-Heath, D.: An improved restricted growth function genetic algorithm for the consensus clustering of retinal nerve fibre data. In: *Proceedings of the 9th annual conference on Genetic and evolutionary computation*. pp. 2174–2181. ACM (2007)
26. Takahashi, R.: A methodology of extended changing crossover operators to solve the traveling salesman problem. In: *2008 Fourth International Conference on Natural Computation*. vol. 1, pp. 263–269 (Oct 2008)
27. Tsutsui, S., Ghosh, A.: A study on the effect of multi-parent recombination in real coded genetic algorithms. In: *1998 IEEE International Conference on Evolutionary Computation Proceedings. IEEE World Congress on Computational Intelligence (Cat. No.98TH8360)*. pp. 828–833 (May 1998)
28. Yoon, Y., Kim, Y.H.: The Roles of Crossover and Mutation in Real-Coded Genetic Algorithms, Bio-Inspired Computational Algorithms and Their Applications, pp. 65–82. InTech (Mar 2012), <https://www.intechopen.com/books/bio-inspired-computational-algorithms-and-their-applications/the-roles-of-crossover-and-mutation-in-real-coded-genetic-algorithms>